

Universidad del Valle de Guatemala

Facultad de Ingeniería

Guatemala, 30 de agosto de 2026

Data Science




Nils Muralles Morales - 23727

Isabella Recinos Rodríguez - 23003


Sofía López Ayerdi - 231929

Análisis exploratorio

El archivo train.csv tiene 7 613 tweets y 5 columnas: id, keyword, location, text y target. Las columnas de text y target están completas. Sin embargo, a location le falta el 33% de los registros y a keyword el 0.8%. Location además, está escrita como texto a mano y no está normalizada.




De los 7613 tweets, 4342 (57%) no hablan de ningún desastre y 3271 (43%). Únicamente es un leve desbalance, por lo que conviene evaluar los modelos con métricas por clase y no solo con la exactitud global.




Los tweets son cortos: Con una mediana de 15 palabras y 107 caracteres y con un máximo de 157 caracteres. Al cruzar la longitud con la categoría, los tweets de desastre real son algo más largos (108 frente a 96 caracteres de media), y esa diferencia se mantiene después de la limpieza (9,1 frente a 8,1 palabras útiles por tweet).

Revisando el texto sin limpiar, el 52 por ciento de los tweets trae un enlace, el 26 por ciento menciona a otra cuenta y el 23 por ciento usa hashtags. Los enlaces son más frecuentes en los tweets de desastre (66 por ciento) que en los demás (41 por ciento), porque muchos enlazan a noticias; es una señal débil pero real.




La variable keyword tiene 221 valores distintos, repartidos de forma pareja. Lo importante es el cruce con target: la proporción de tweets de desastre cambia de forma extrema según la palabra clave. Hay keywords como aftershock, ruin o body bags donde casi ningún tweet es un desastre real (se usan en sentido figurado), y otras como debris, wreckage, derailment u outbreak donde casi todos lo son. Esto convierte a keyword en una variable muy informativa para el modelo.



Hay 110 tweets con texto exactamente repetido y 18 textos idénticos que aparecen etiquetados como desastre y como no desastre a la vez. Estos casos se tratan en el preprocesamiento. Los 18 contradictorios se eliminan y de los duplicados exactos se conserva una sola copia. El dataset limpio queda con 7484 tweets.

Vale la pena mirar bigramas porque el contexto separa mucho mejor las clases que las palabras sueltas. Los bigramas más frecuentes de los tweets de desastre son eventos completos: "suicide bomber", "oil spill", "california wildfire", "severe thunderstorm", "burning building", "suicide bombing". Los de no desastre son expresiones coloquiales o usos figurados: "body bag", "look like", "feel like", "liked video". Una palabra como "burning" o "body" por sí sola es ambigua, pero "burning building" o "body bag" ya casi no lo son. Explorar trigramas aporta menos, porque al ser tweets cortos y con vocabulario disperso la mayoría de trigramas aparecen muy pocas veces.




Análisis de sentimientos y negatividad

Se usaron dos recursos, porque miden cosas distintas. El primero es el Opinion Lexicon de Hu y Liu (2004), que son dos listas de palabras en inglés etiquetadas como positivas (unas 2000) o negativas (unas 4800). Con estas listas se puede contar literalmente cuántas palabras positivas y negativas aparecen en cada tweet, que es lo que pide la rúbrica. El segundo es VADER (Hutto y Gilbert, 2014), un analizador pensado para redes sociales que además de mirar palabras entiende negaciones, intensificadores, mayúsculas y signos de exclamación, y devuelve un puntaje continuo entre menos uno y uno. Ese puntaje continuo sirve para ordenar los tweets de más negativo a más positivo y para comparar grupos, cosa que el simple conteo no hace bien porque genera muchos empates. Ambos vienen incluidos en la librería NLTK.

Para cada tweet se tomó el texto limpio pero sin lematizar (minúsculas, sin enlaces ni hashtags, pero conservando las palabras completas y las negaciones), se separó en palabras y cada palabra se marcó como positiva, negativa o neutra según apareciera en las listas de Hu y Liu. La puntuación del tweet es el número de palabras positivas menos el número de negativas, y se clasifica como positivo si esa resta da mayor que cero, negativo si da menor que cero y neutral si da cero.

Con este método, 3 523 tweets (47 por ciento) quedan como negativos, 2 890 (39 por ciento) como neutrales y 1 071 (14 por ciento) como positivos. VADER se aplica sobre el texto original y clasifica con los umbrales que recomiendan sus autores: puntaje mayor o igual a 0.05 es positivo, menor o igual a menos 0,05 es negativo y en medio neutral. Da un

reparto parecido en la parte negativa pero distinto en el resto: 49 por ciento negativos, 26 por ciento neutrales y 25 por ciento positivos. Los dos métodos coinciden en la clasificación del 61 por ciento de los tweets; la mayor diferencia está en que el conteo de Hu y Liu marca como neutrales muchos tweets que VADER considera positivos, porque VADER capta matices de tono que no dependen de tener una palabra concreta de la lista. El conteo simple tampoco maneja las negaciones (en "not good" cuenta una palabra positiva), cosa que VADER sí hace; por eso se reportan los dos y se usa VADER como medida principal para ordenar y comparar. En ambos casos el resultado general es el mismo: predominan los tweets negativos, lo cual tiene sentido en un dataset centrado en desastres.




A partir del puntaje de VADER se creó la variable negatividad como $(1 - \text{compound}) / 2$, que la deja en una escala de 0 a 1 donde 0 es un tweet muy positivo y 1 un tweet muy negativo. Todas las columnas de sentimiento, incluida esta, se guardaron en `train_sentiment.csv`. Este archivo queda listo para el punto 10 del laboratorio, donde se reentrena el modelo de clasificación agregando la negatividad como variable y se discute si mejora los resultados.

Modelo de clasificación

Para la clasificación de tweets se probaron cuatro algoritmos sobre una representación TF-IDF del texto preprocesado: Regresión Logística, Naive Bayes Multinomial, Support Vector Machine lineal y Random Forest. Los cuatro modelos se entrenaron sobre el 80% de los datos y se evaluaron sobre el 20% restante, con una partición estratificada por la variable target para conservar la proporción de clases (57.4% no desastre / 42.6% desastre).


El modelo con mejor desempeño fue la Regresión Logística, con un F1-score de 0.734, accuracy de 0.796, precision de 0.827 y recall de 0.659. Se seleccionó con base en el F1-score por ser la métrica que mejor balancea precision y recall, relevante en este problema porque tanto los falsos negativos como los falsos positivos tienen costo. El uso de bigramas junto a unigramas permite capturar contexto local, lo cual mejora la representación frente a un enfoque de solo unigramas.

Para verificar que este resultado no dependía del split particular, se corrió una validación cruzada de 5 folds sobre el modelo seleccionado, obteniendo un F1 promedio de 0.746 (± 0.012), consistente con el resultado del split original y con varianza baja entre folds. Cabe notar que sin barajar los datos, el F1 promedio caía a 0.550 con una desviación mucho mayor (± 0.082). Este hallazgo confirma que el desempeño del modelo es estable y generaliza adecuadamente.




Variable de negatividad

Para evaluar el aporte de la variable de negatividad se reentrenó el mismo modelo agregando la negatividad como una columna numérica adicional a la matriz TF-IDF. Antes de hacer esto se analizó la relación entre negatividad y target:



Los tweets de desastre real tienen, en promedio, mayor negatividad (media de 0.63 y mediana de 0.66) que los de no desastre (media de 0.53 y mediana de 0.50), sin embargo, la correlación con target es baja (0.22) y las distribuciones se solapan casi por completo. Hay muchos tweets de desastre con tono neutro o incluso positivo (redactados como

noticia) y muchos no-desastres con tono muy negativo (quejas, sarcasmo, lenguaje figurado). Esto anticipa que la negatividad, por sí sola, será un predictor débil.



Al realizar el reentrenamiento se realizó una comparación de los modelos, en la cual se observó que el modelo con la variable no mejoró, incluso quedó levemente por debajo del modelo base. El recall no cambió, y la caída se concentró en precisión y accuracy: al agregar la variable, el modelo empezó a marcar como "desastre" algunos tweets negativos que en realidad no lo eran. Para confirmar que el resultado no dependía del split, se corrió la misma validación cruzada de 5 folds usada para el modelo base: el F1 promedio bajó de 0.750 a 0.746, y el modelo aumentado no superó al base en ninguno de los 5 folds, una diferencia menor que la variabilidad natural entre folds.

La regresión logística sí le asigna peso a la variable (coeficiente 1.53, odds ratio 4.6), siendo la feature número 37 de 8001 por magnitud del coeficiente, pero ese peso no se traduce en mejor generalización: la información que aporta ya está contenida en los n-gramas, porque muchas de las palabras más negativas (fire, dead, crash) son también las más predictivas de desastre.

En conclusión, la inclusión de la variable de negatividad no mejoró los resultados de clasificación. El F1 se mantuvo prácticamente igual, con una variación negativa y despreciable tanto en el split de prueba (-0.008) como en la validación cruzada (-0.005). Se conserva por lo tanto el modelo base (solo TF-IDF), más simple y sin dependencia del módulo de análisis de sentimiento, sin que esto implique una pérdida real de desempeño. Esto confirma lo observado en la sección de sentimientos, los tweets de desastre real sí tienden a ser algo más negativos que los de no desastre, pero la diferencia es insuficiente para usarse como predictor por sí sola.

Enlaces

- Repositorio de github: <https://github.com/nilsmuralles/DataScience-Lab5.git>
- Reporte: https://docs.google.com/document/d/10CaFnOO_KuUsWduvws82x56_2Nt4sOpKf-z42YaLRQw/edit?usp=sharing

Referencias

Hu, M. y Liu, B. (2004). Mining and Summarizing Customer Reviews. Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

Hutto, C. J. y Gilbert, E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. Proceedings of the Eighth International AAAI Conference on Weblogs and Social Media.